

#### Roteiro

- ETL
- Airflow
- Solução

#### ETL - O que é?







- Falhas
- Monitoramento
- Dependências
- Escalabilidade

Tentar recuperar quantas vezes? Com que frequência?

- Monitoramento
- Dependências
- Escalabilidade

Tentar recuperar quantas vezes? Com que frequência?

Monitoramento

Quando tempo o processo demora pra executar? O que falhou e o que deu certo?

- Dependências
- Escalabilidade

Tentar recuperar quantas vezes? Com que frequência?

Monitoramento

Quando tempo o processo demora pra executar? O que falhou e o que deu certo?

Dependências

Sincronizar tarefas em máquinas cron?

Escalabilidade

Tentar recuperar quantas vezes? Com que frequência?

## Monitoramento

Quando tempo o processo demora pra executar? O que falhou e o que deu certo?

## Dependências

Sincronizar tarefas em máquinas cron?

## Escalabilidade

Falta scheduler centralizado


Airflow é uma plataforma para **criar**, **agendar** e **monitorar** *workflows* (*pipelines*) programaticamente.




# ETL Machine Learning Execução de Scripts

#### **Airflow** - Componentes

- Webserver
- Scheduler
- Executor
- Metadata Database



#### **Airflow** - DAG



#### Airflow - Integrações

#### **Oficiais**


- Microsoft Azure
- Amazon Web Services
- Databricks
- Google Cloud Platform
- Qubole

## Plugins github.com/airflow-plugins


- Google Analytics
- Mongo
- Github
- REST Like API
- Google Sheets

. . .


#### Airflow - Interface (DAGs)




#### Airflow - Interface (Árvore)




#### Airflow - Interface (Grafo)




#### Airflow - Interface (Variáveis)




#### Airflow - Interface (Gráfico Gantt)




#### Airflow - Interface (Duração das Tasks)



#### Airflow - Interface (Código)



#### Airflow - Interface (Menu de Contexto da Task)




#### Airflow - Exemplo ETL

#### Web Crawler

https://www.infomoney.com.br/mercados/cambio

#### Airflow - DAG Rede Frota (Clusterização de Clientes)



Implementado a nível de código;

Realização de Testes;

Não funciona para Streaming;

#### **Outras Ferramentas**



Luigi



0-0-731-E

**Oozie** 



**Spark Streaming** 



**Data Factory** 



**Cloud Composer** 



Glue

#### Extra



Podcast: Airflow in Practice with Chaim Turkel



Comunidade Brasileira de Ciência de Dados

datahackers.com.br



Playlist
Apache Airflow
Tutorials

softwareengineeringdaily.com

## Dúvidas?